

Bias-Variance Decomposition in Practice

Исследовательский проект по регрессионным моделям

Аннотация

В работе численно исследуется разложение квадратичной ошибки на Bias², Variance и Noise. Monte Carlo эксперименты сравнивают Polynomial Ridge, Decision Tree, KNN, Random Forest и MLP. Дополнительные эксперименты показывают влияние размера обучающей выборки и шума. На данных Diabetes и Linnerud устойчивость фиксированных конфигураций оценивается через repeated cross-validation и paired bootstrap.

1. Постановка задачи

Пусть $Y = f(X) + \varepsilon$, где $\mathbb{E}[\varepsilon | X] = 0$ и $\mathbb{V}[\varepsilon | X] = \sigma^2$. Для squared loss выполняется

$$\mathbb{E}_{D,\varepsilon} [(Y - \hat{f}_D(x))^2] = \left(\mathbb{E}_D[\hat{f}_D(x)] - f(x) \right)^2 + \mathbb{V}_D[\hat{f}_D(x)] + \sigma^2.$$

Синтетические данные генерируются для $f(x) = \sin(2x) + 0.2x^2$ на $X \sim U[-3, 3]$. Для каждой конфигурации используются 50 обучающих выборок по 160 объектов и общая evaluation grid из 240 точек. Evaluation grid не участвует в fit. Test noise генерируется независимо от train noise.

Train datasets одинаковы для всех сравниваемых моделей. Data seed, model seed и test-noise seed принадлежат разным последовательностям. Для Random Forest и MLP model seed меняется между повторами. Поэтому их variance включает чувствительность к данным и stochasticity алгоритма.




Рис. 1: Синтетическая выборка и распределение целевой переменной

2. Сложность модели

Для Polynomial Ridge изменяется степень полинома, для дерева и Random Forest максимальная глубина, для KNN число соседей, для MLP ширина скрытого слоя. Полиномиальные признаки и масштабирование находятся внутри sklearn Pipeline.

Bias-variance trade-off across five model families




Рис. 2: Компоненты ошибки при изменении сложности пяти моделей

Модель	Параметр	Bias ²	Variance	Expected MSE
Polynomial Ridge	degree=7	0.001	0.007	0.130
KNN	n_neighbors=12	0.006	0.014	0.143
MLP	hidden_width=64	0.010	0.012	0.145
Random Forest	max_depth=4	0.008	0.025	0.156
Decision Tree	max_depth=5	0.002	0.055	0.180

Polynomial Ridge степени 7 показывает наименьший expected MSE около 0.130. KNN и MLP дают близкие значения около 0.143 и 0.145. У Decision Tree после глубины 5 уменьшение bias сопровождается ростом variance. Random Forest снижает variance относительно одиночного дерева благодаря усреднению.

Empirical MSE близок к сумме Bias², Variance и Noise. Оставшийся гар связан с конечным числом Monte Carlo повторений и не является отдельным компонентом ошибки.

3. Размер выборки, шум и MLP

Для Decision Tree глубины 6 увеличение train size с 40 до 320 объектов уменьшает variance примерно с 0.130 до 0.049. При росте σ увеличивается не только σ^2 , но и нестабильность fitted function на конечной выборке.

MLP history строится через warm_start=True и max_iter=1. Каждый вызов fit добавляет одну эпоху Adam. Предупреждение о достижении одной итерации ожидаемо и подавляется только внутри этого цикла. StandardScaler обучается отдельно на train part как для признаков, так и для целевой переменной.




Рис. 3: Влияние размера обучающей выборки и наблюдаемого шума




Рис. 4: Train и validation RMSE при последовательном обучении MLP

4. Реальные данные

Diabetes содержит 442 наблюдения и 10 признаков. Linnerud содержит 20 наблюдений и 3 признака, а целевой переменной выбрана масса тела. Используются исходные признаки без дополнительного feature engineering. Операции масштабирования находятся внутри pipeline и обучаются заново в каждом fold.

Фиксированные конфигурации Dummy, Ridge, Decision Tree, Random Forest, Gradient Boosting и MLP оцениваются на одинаковых разбиениях RepeatedKFold с 5 folds и 3 повторами. Это сравнение заданных конфигураций, а не поиск лучшего представителя каждого семейства.




Рис. 5: Средний RMSE и стандартное отклонение на repeated CV

Датасет	Модель	RMSE	RMSE std	R^2
Diabetes	Ridge	54.857	3.046	0.486
Diabetes	MLP	55.982	4.321	0.464
Diabetes	Gradient Boosting	56.533	3.163	0.455
Diabetes	Random Forest	57.349	3.916	0.438
Diabetes	Decision Tree	64.303	3.789	0.293
Diabetes	Dummy	77.159	3.155	-0.016
Linnerud-Weight	Ridge	22.788	10.018	-0.597
Linnerud-Weight	Decision Tree	22.967	8.666	-1.044
Linnerud-Weight	Random Forest	23.247	8.096	-0.907
Linnerud-Weight	Dummy	23.779	9.063	-0.785
Linnerud-Weight	MLP	26.518	8.396	-1.453
Linnerud-Weight	Gradient Boosting	28.584	9.599	-1.491

На Diabetes минимальный средний RMSE показывает Ridge со значением около 54.86. MLP, Gradient Boosting и Random Forest находятся рядом, поэтому результат не поддерживает общий вывод о превосходстве одного семейства. На Linnerud средний R^2 отрицателен у всех конфигураций, а разброс RMSE велик. Двадцати наблюдений недостаточно для устойчивого ранжирования моделей.

5. Paired bootstrap

Для каждого датасета bootstrap indices генерируются заранее и повторно используются всеми моделями. Model seed остаётся независимым от bootstrap seed. Истинная функция регрессии на реальных данных неизвестна. Поэтому bootstrap_variance измеряет чувствительность к перевыборке, а proxy_bias2 вычисляется относительно Gradient Boosting reference model. Эти величины не образуют точное классическое разложение.




Рис. 6: Bootstrap variance и proxy bias на реальных данных

На Diabetes Decision Tree имеет наибольшую bootstrap variance среди рассмотренных конфигураций. Для Linnerud proxy оценки особенно чувствительны к малому train split и рассматриваются только как диагностика стабильности.

6. Ограничения и выводы

Monte Carlo оценки используют конечное число повторений. Оси сложности разных семейств не сопоставимы численно. Variance Random Forest и MLP включает stochasticity алгоритма. На реальных данных неизвестны $f(x)$ и истинный уровень noise. Proxy bias зависит от reference model. Выводы по реальным данным относятся только к фиксированным конфигурациям, а Linnerud слишком мал для уверенного выбора модели.

Эксперименты воспроизводят основную закономерность bias-variance trade-off. Гибкость снижает bias до точки, после которой variance начинает увеличивать общую ошибку. Дополнительные данные уменьшают variance, а шум задаёт неустранимую часть ошибки. На реальных данных repeated CV и paired bootstrap позволяют обсуждать устойчивость без ложного отождествления proxy величин с точным Bias².