

Bias-Variance Decomposition in Practice

Исследовательский проект по регрессионным моделям

Аннотация

Проект исследует связь сложности регрессионной модели с bias, variance и квадратичной ошибкой. На синтетических данных компоненты оцениваются напрямую по независимым обучающим выборкам. На Diabetes и California Housing используются repeated cross-validation и paired bootstrap. Для реальных данных проверяется точное тождество квадратичной ошибки без подмены неизвестного смещения расстоянием до эталонной модели.

1. Синтетический эксперимент

Пусть $Y = f(X) + \varepsilon$, где $\mathbb{E}[\varepsilon | X] = 0$ и $\mathbb{V}[\varepsilon | X] = \sigma^2$. Для squared loss выполняется

$$\mathbb{E}_{D,\varepsilon} [(Y - \hat{f}_D(x))^2] = \left(\mathbb{E}_D[\hat{f}_D(x)] - f(x) \right)^2 + \mathbb{V}_D[\hat{f}_D(x)] + \sigma^2.$$

Используется функция $f(x) = \sin(2x) + 0.2x^2$ на $X \sim U[-3, 3]$ и $\sigma = 0.35$. Для каждой конфигурации строятся 50 независимых обучающих выборок по 160 объектов. Все модели получают одни и те же выборки и общую сетку из 240 точек, которая не передается в fit. Случайность данных, модели и тестового шума задается разными seed sequences. Variance Random Forest и MLP включает изменение данных и случайность алгоритма.

На конечном числе повторов наивная оценка squared bias содержит Monte Carlo добавку. Для m повторов используется поправка

$$\widehat{Bias^2}_{\text{corr}} = \frac{1}{n} \sum_i (\bar{f}(x_i) - f(x_i))^2 - \frac{\widehat{Variance}}{m}.$$

Variance оценивается с поправкой Бесселя. Из-за несмещенности исправленный Bias² может быть немного отрицательным около нуля. Полосы на графике получены bootstrap перывыборкой 50 prediction vectors.

Модель	Параметр	Bias ²	Variance	MSE	Время, с
Polynomial Ridge	degree=7	0.001	0.007	0.130	0.06
MLP	hidden_width=256	0.001	0.007	0.131	17.68
KNN	n_neighbors=12	0.006	0.015	0.143	0.05
Random Forest	max_depth=4	0.008	0.026	0.156	2.41
Decision Tree	max_depth=5	0.001	0.056	0.180	0.03

Polynomial Ridge степени 7 показывает expected MSE 0.1305. MLP ширины 256 дает 0.1312, KNN с 12 соседями дает 0.1428. У дерева corrected Bias² после глубины 5 близок к нулю в пределах полосы, поэтому прежний визуальный хвост нельзя интерпретировать как дальнейшее устойчивое снижение bias. Рост ошибки дерева связан прежде всего с variance. У полиномиальной модели ошибка выходит на плато, а у однослойной MLP не образуется U-shaped curve на исследованной сетке.

Bias-variance trade-off across five model families




Рис. 1: Компоненты ошибки и неопределенность Bias² и Variance

2. Размер выборки и выбор сложности

Для Decision Tree глубины 6 увеличение train size с 40 до 320 объектов снижает variance с 0.134 до 0.050. При $\sigma = 0.9$ noise равен 0.81 и становится крупнейшей частью expected MSE.




Рис. 2: Влияние размера обучающей выборки и уровня шума

GridSearchCV теперь использует выборку того же размера, что и Monte Carlo эксперимент. Набор уровней сложности также совпадает. CV и minimum expected MSE выбирают одинаковые параметры для четырех семейств из пяти. Для дерева CV выбирает глубину 4, а Monte Carlo минимум достигается при глубине 5.

Модель	CV	Monte Carlo	Совпало	Время, с
Polynomial Ridge	7	7	да	0.06
MLP	256	256	да	5.66
KNN	12	12	да	0.05
Random Forest	4	4	да	1.95
Decision Tree	4	5	нет	0.03

Таблицы содержат wall-clock время полного набора fit для синтетических конфигураций и среднее время одного CV fit для реальных данных. Эти значения нужны для сравнения вычислительной цены, но зависят от компьютера.

3. Нейронная сеть

Отдельный эксперимент меняет ширину до 256, число скрытых слоев до трех и L2 параметр α . Для ширины от 128 до 256 expected MSE почти не меняется. Variance также не растет. Это не подтверждает универсальный тезис о том, что любое увеличение ширины обязательно ведет к переобучению. На этой одномерной задаче Adam, L2 и остановка по отсутствию улучшения loss ограничивают эффективную сложность сети. Переход от двух слоев к трем повышает variance с 0.0109 до 0.0128 и expected MSE с 0.1333 до 0.1352.




Рис. 3: Ширина, глубина и L2 как независимые оси сложности MLP

История обучения строится через `partial_fit`. Это сохраняет optimizer state между эпохами и не создает искусственных однопроходных вызовов `fit`. К тысячной эпохе train RMSE снижается до 0.326, ниже заданного $\sigma = 0.35$. Validation RMSE остается около 0.374. Сеть теперь достаточно обучена, а разрыв между кривыми показывает цену подгонки шумовой части train sample.




Рис. 4: Train и validation RMSE при последовательном обучении MLP

4. Реальные данные

Diabetes содержит 442 наблюдения и 10 признаков. California Housing содержит 20640 наблюдений. Для практического полного запуска один раз выбираются 5000 строк по фиксиро-

ванному seed. Исходный датасет загружается средствами scikit-learn и остается в локальном cache. Масштабирование Ridge и MLP находится внутри Pipeline и обучается заново на каждом fold.

Модели сравниваются на одинаковых разбиениях RepeatedKFold с 5 folds и 3 повторами. На Diabetes Ridge показывает $RMSE\ 54.86 \pm 3.05$. MLP и Gradient Boosting находятся в пределах наблюдаемого разброса. На California Housing MLP показывает $RMSE\ 0.570 \pm 0.019$, Random Forest дает 0.612 ± 0.021 . Dummy заметно хуже обучаемых моделей на обоих наборах.




Рис. 5: Repeated cross-validation на двух реальных наборах

Датасет	Модель	RMSE	Std	R^2	Время, с
California Housing	MLP	0.570	0.019	0.758	0.488
California Housing	Random Forest	0.612	0.021	0.721	0.245
California Housing	Gradient Boosting	0.696	0.015	0.640	0.430
California Housing	Ridge	0.759	0.041	0.570	0.001
California Housing	Decision Tree	0.763	0.019	0.568	0.007
California Housing	Dummy	1.161	0.022	-0.001	0.000
Diabetes	Ridge	54.857	3.046	0.486	0.001
Diabetes	MLP	55.982	4.321	0.464	0.029
Diabetes	Gradient Boosting	56.533	3.163	0.455	0.047
Diabetes	Random Forest	57.349	3.916	0.438	0.082
Diabetes	Decision Tree	64.303	3.789	0.293	0.001
Diabetes	Dummy	77.159	3.155	-0.016	0.001

5. Сложность на Diabetes

Для одного train-test split используются общие 30 bootstrap samples. У Ridge усиление регуляризации снижает variance со 106 до 51, при этом средний bootstrap MSE остается около 2885. У дерева минимум среднего bootstrap MSE наблюдается при глубине 2, после чего variance быстро растет. Для KNN variance падает с ростом числа соседей. У MLP ширина 64 устойчивее ширины 128 при всех трех значениях α . Таким образом, реальная часть исследует не только фиксированные конфигурации, но и траектории сложности на десяти признаках.




Рис. 6: Ошибка и bootstrap variance при изменении сложности на Diabetes

6. Точное bootstrap тождество

Истинная regression function на реальных данных неизвестна. Поэтому bias и irreducible noise раздельно не оцениваются. Для фиксированного test set и prediction matrix проверяется точное тождество

$$\frac{1}{B} \sum_{b=1}^B MSE(y, \hat{f}_b) = MSE(y, \bar{f}) + \frac{1}{n} \sum_i Var_b \left(\hat{f}_b(x_i) \right).$$

Первое слагаемое объединяет систематическую ошибку относительно наблюдаемых targets, test noise и эффект выбранного split. Его нельзя называть Bias². Второе слагаемое измеряет нестабильность прогноза при перевыборке. Identity gap во всех строках находится на уровне машинной точности.




Рис. 7: Точное тождество для paired bootstrap predictions

7. Выводы и ограничения

Классический bias-variance механизм ясно виден у Decision Tree, KNN и Random Forest. Для Polynomial Ridge после достаточной степени возникает плато. У MLP ширина сама по себе не вызывает роста variance на синтетической задаче, но дополнительная глубина и реальный многомерный набор показывают менее устойчивые режимы. Поэтому общий вывод формулируется по наблюдаемым траекториям, а не как универсальное свойство всех пяти семейств.

Оценки зависят от конечного числа Monte Carlo и bootstrap повторов. Полосы неопределенности отражают переВыборку prediction vectors, а не полный повтор всего исследования. Время обучения зависит от оборудования. На реальных данных тождество разделяет ошибку среднего прогноза и нестабильность, но не разделяет bias и noise без дополнительных предположений о неизвестной регрессионной функции.