

# Bias-Variance Decomposition in Practice

Исследовательский проект по регрессионным моделям

## Аннотация

Проект исследует связь сложности регрессионной модели с bias, variance и квадратичной ошибкой. На синтетических данных компоненты оцениваются напрямую по независимым обучающим выборкам. На Diabetes и California Housing используются repeated cross-validation и paired bootstrap. Для реальных данных проверяется точное тождество квадратичной ошибки без подмены неизвестного смещения расстоянием до эталонной модели.

## 1. Синтетический эксперимент

Пусть  $Y = f(X) + \varepsilon$ , где  $\mathbb{E}[\varepsilon | X] = 0$  и  $\mathbb{V}[\varepsilon | X] = \sigma^2$ . Для squared loss выполняется

$$\mathbb{E}_{D,\varepsilon} [(Y - \hat{f}_D(x))^2] = \left( \mathbb{E}_D[\hat{f}_D(x)] - f(x) \right)^2 + \mathbb{V}_D[\hat{f}_D(x)] + \sigma^2.$$

Используется функция  $f(x) = \sin(2x) + 0.2x^2$  на  $X \sim U[-3, 3]$  и  $\sigma = 0.35$ . Для каждой конфигурации строятся 50 независимых обучающих выборок по 160 объектов. Все модели получают одни и те же выборки и общую сетку из 240 точек, которая не передается в fit. Случайность данных, модели и тестового шума задается разными seed sequences. Variance Random Forest и MLP включает изменение данных и случайность алгоритма.

На конечном числе повторов наивная оценка squared bias содержит Monte Carlo добавку. Для  $m$  повторов используется поправка

$$\widehat{Bias^2}_{\text{corr}} = \frac{1}{n} \sum_i (\bar{f}(x_i) - f(x_i))^2 - \frac{\widehat{Variance}}{m}.$$

Variance оценивается с поправкой Бесселя. Из-за несмещенности исправленный Bias<sup>2</sup> может быть немного отрицательным около нуля. Полосы на графике получены bootstrap перывыборкой 50 prediction vectors.

| Модель           | Параметр         | Bias <sup>2</sup> | Variance | MSE   | Время, с |
|------------------|------------------|-------------------|----------|-------|----------|
| Polynomial Ridge | degree=7         | 0.001             | 0.007    | 0.130 | 0.05     |
| MLP              | hidden_width=256 | 0.001             | 0.007    | 0.131 | 17.17    |
| KNN              | n_neighbors=12   | 0.006             | 0.015    | 0.143 | 0.05     |
| Random Forest    | max_depth=4      | 0.008             | 0.026    | 0.156 | 2.40     |
| Decision Tree    | max_depth=5      | 0.001             | 0.056    | 0.180 | 0.03     |

Polynomial Ridge степени 7 показывает expected MSE 0.1305. MLP ширины 256 дает 0.1312, KNN с 12 соседями дает 0.1428. У дерева corrected Bias<sup>2</sup> после глубины 5 близок к нулю в пределах полосы, поэтому прежний визуальный хвост нельзя интерпретировать как дальнейшее устойчивое снижение bias. Рост ошибки дерева связан прежде всего с variance. У полиномиальной модели ошибка выходит на плато, а у однослойной MLP не образуется U-shaped curve на исследованной сетке.

Bias-variance trade-off across five model families




Рис. 1: Компоненты ошибки и неопределенность Bias<sup>2</sup> и Variance

## 2. Размер выборки и выбор сложности

Для Decision Tree глубины 6 увеличение train size с 40 до 320 объектов снижает variance с 0.134 до 0.050. При  $\sigma = 0.9$  noise равен 0.81 и становится крупнейшей частью expected MSE.




Рис. 2: Влияние размера обучающей выборки и уровня шума

GridSearchCV теперь использует выборку того же размера, что и Monte Carlo эксперимент. Набор уровней сложности также совпадает. CV и minimum expected MSE выбирают одинаковые параметры для четырех семейств из пяти. Для дерева CV выбирает глубину 4, а Monte Carlo минимум достигается при глубине 5.

| Модель           | CV  | Monte Carlo | Совпало | Время, с |
|------------------|-----|-------------|---------|----------|
| Polynomial Ridge | 7   | 7           | да      | 0.05     |
| MLP              | 256 | 256         | да      | 5.49     |
| KNN              | 12  | 12          | да      | 0.05     |
| Random Forest    | 4   | 4           | да      | 1.74     |
| Decision Tree    | 4   | 5           | нет     | 0.03     |

Таблицы содержат wall-clock время полного набора fit для синтетических конфигураций и среднее время одного CV fit для реальных данных. Эти значения нужны для сравнения вычислительной цены, но зависят от компьютера.

### 3. Нейронная сеть

Отдельный эксперимент меняет ширину до 256, число скрытых слоев до трех и L2 параметр  $\alpha$ . Для ширины от 128 до 256 expected MSE почти не меняется. Variance также не растет. Это не подтверждает универсальный тезис о том, что любое увеличение ширины обязательно ведет к переобучению. На этой одномерной задаче Adam, L2 и остановка по отсутствию улучшения loss ограничивают эффективную сложность сети. Переход от двух слоев к трем повышает variance с 0.0109 до 0.0128 и expected MSE с 0.1333 до 0.1352.




Рис. 3: Ширина, глубина и L2 как независимые оси сложности MLP

История обучения строится через `partial_fit`. Это сохраняет optimizer state между эпохами и не создает искусственных однопроходных вызовов `fit`. К тысячной эпохе train RMSE снижается до 0.326, ниже заданного  $\sigma = 0.35$ . Validation RMSE остается около 0.374. Сеть теперь достаточно обучена, а разрыв между кривыми показывает цену подгонки шумовой части train sample.




Рис. 4: Train и validation RMSE при последовательном обучении MLP

### 4. Реальные данные

Diabetes содержит 442 наблюдения и 10 признаков. California Housing содержит 20640 наблюдений. Для практического полного запуска один раз выбираются 5000 строк по фиксиро-

ванному seed. Исходный датасет загружается средствами scikit-learn и остается в локальном cache. Масштабирование Ridge и MLP находится внутри Pipeline и обучается заново на каждом fold.

Модели сравниваются на одинаковых разбиениях RepeatedKFold с 5 folds и 3 повторами. На Diabetes Ridge показывает  $RMSE\ 54.86 \pm 3.05$ . MLP и Gradient Boosting находятся в пределах наблюдаемого разброса. На California Housing MLP показывает  $RMSE\ 0.570 \pm 0.019$ , Random Forest дает  $0.612 \pm 0.021$ . Dummy заметно хуже обучаемых моделей на обоих наборах.




Рис. 5: Repeated cross-validation на двух реальных наборах

| Датасет            | Модель            | RMSE   | Std   | $R^2$  | Время, с |
|--------------------|-------------------|--------|-------|--------|----------|
| California Housing | MLP               | 0.570  | 0.019 | 0.758  | 0.470    |
| California Housing | Random Forest     | 0.612  | 0.021 | 0.721  | 0.230    |
| California Housing | Gradient Boosting | 0.696  | 0.015 | 0.640  | 0.416    |
| California Housing | Ridge             | 0.759  | 0.041 | 0.570  | 0.001    |
| California Housing | Decision Tree     | 0.763  | 0.019 | 0.568  | 0.007    |
| California Housing | Dummy             | 1.161  | 0.022 | -0.001 | 0.000    |
| Diabetes           | Ridge             | 54.857 | 3.046 | 0.486  | 0.001    |
| Diabetes           | MLP               | 55.982 | 4.321 | 0.464  | 0.028    |
| Diabetes           | Gradient Boosting | 56.533 | 3.163 | 0.455  | 0.045    |
| Diabetes           | Random Forest     | 57.349 | 3.916 | 0.438  | 0.080    |
| Diabetes           | Decision Tree     | 64.303 | 3.789 | 0.293  | 0.001    |
| Diabetes           | Dummy             | 77.159 | 3.155 | -0.016 | 0.001    |

## 5. Сложность на Diabetes

Для одного train-test split используются общие 30 bootstrap samples. У Ridge усиление регуляризации снижает variance со 106 до 51, при этом средний bootstrap MSE остается около 2885. У дерева минимум среднего bootstrap MSE наблюдается при глубине 2, после чего variance быстро растет. Для KNN variance падает с ростом числа соседей. У MLP ширина 64 устойчивее ширины 128 при всех трех значениях  $\alpha$ . Таким образом, реальная часть исследует не только фиксированные конфигурации, но и траектории сложности на десяти признаках.




Рис. 6: Ошибка и bootstrap variance при изменении сложности на Diabetes

## 6. Точное bootstrap тождество

Истинная regression function на реальных данных неизвестна. Поэтому bias и irreducible noise раздельно не оцениваются. Для фиксированного test set и prediction matrix проверяется точное тождество

$$\frac{1}{B} \sum_{b=1}^B MSE(y, \hat{f}_b) = MSE(y, \bar{f}) + \frac{1}{n} \sum_i Var_b \left( \hat{f}_b(x_i) \right).$$

Первое слагаемое объединяет систематическую ошибку относительно наблюдаемых targets, test noise и эффект выбранного split. Его нельзя называть Bias<sup>2</sup>. Второе слагаемое измеряет нестабильность прогноза при перевыборке. Identity gap во всех строках находится на уровне машинной точности.




Рис. 7: Точное тождество для paired bootstrap predictions

## 7. Выводы и ограничения

Классический bias-variance механизм ясно виден у Decision Tree, KNN и Random Forest. Для Polynomial Ridge после достаточной степени возникает плато. У MLP ширина сама по себе не вызывает роста variance на синтетической задаче, но дополнительная глубина и реальный многомерный набор показывают менее устойчивые режимы. Поэтому общий вывод формулируется по наблюдаемым траекториям, а не как универсальное свойство всех пяти семейств.

Конечное число Monte Carlo повторов особенно важно там, где corrected Bias<sup>2</sup> почти равен нулю. Поэтому вывод о глубоких деревьях опирается не на малые различия точечных оценок, а на совместное чтение линии и полосы неопределенности. Bootstrap на Diabetes и California Housing отвечает на другой вопрос. Он показывает чувствительность к train data, но не разделяет bias и noise без предположений о неизвестной регрессионной функции. Время обучения приведено только как ориентир внутри одного запуска, поскольку оно зависит от оборудования.